Le MapReduce

# Programmation Fonctionnelle Objectif

- Introduction aux principes de la programmation fonctionnelle
- L'exemple du MapReduce
- Programmation fonctionnelle en Python

#### Pré-requis

- Avoir les base en Python
- Connaissance algorithmiques de base

Un exemple

Considérez les fonctions suivantes

```
int fact_iter(int n)
        int res=1,i;
        for(i=1; i<=n; i++) res = res*i;
        return res;
et
int fact_rec(int n)
        if(n<=1) return 1;</pre>
        else return n*fact_rec(n-1);
```

#### Idées principales

- La fonction fact\_rect est l'implémentation qui est la plus proche de la philosophie de la programmation fonctionnelle:
  - Style déclaratif vs impératif
  - Récursivité vs boucle
- Pourquoi opter pour ce style
  - Donne des programmes plus concis et clairs
  - Fournis une bonne généricité

# Programmation Fonctionnelle Un autre exemple

```
int fact (int n) { ... }
int myDouble (int n) { return 2*n; }
int square (int n) { return n*n; }

La programmation fonctionnelle demande d'avoir une fonction du style:
int apply_a_func (?FUNCTION? F, int n) { return f(n); }
```

Qui pourra être utiliser comme suit:

```
apply_a_func (fact, 5) // \Rightarrow 120
apply_a_func (myDouble, 5) // \Rightarrow 10
apply_a_func (square, 5) // \Rightarrow 25
```

#### Fonctions d'ordre supérieur

- Une fonction d'ordre supérieur est une fonction qui prend comme argument au moins une autre fonction.
- intérêt:
  - Elle permet de concevoir des programmes génériques
  - Permet de programmer une seule fois l'algorithme générique, et le réutiliser pour chaque opération

## Programmation Fonctionnelle Définition

La programmation fonctionnelle est un paradigme de programmation qui s'appuie sur les fonctions d'ordre supérieur, la composition des fonctions et l'immuabilité des données, dans le but d'écrire un code déclaratif.

Les languages de programmation modernes tels que Python, Java, Scala sont adaptés pour ce style de programmation.

## Programmation Fonctionnelle MapReduce

MapReduce est un modèle de programmation fonctionnelle conçu pour le traitement distribué de grandes quantités de données sur un cluster. Il repose sur deux opérations principales :

Map → Transforme les données d'entrée en une collection de paires clé-valeur.

Reduce → Agrège les valeurs associées à chaque clé pour produire un résultat final.

Ce modèle est utilisé dans des systèmes comme Hadoop et Spark pour le traitement parallèle et scalable de données massives.

Dans ce cours, nous allons voir une version simplifiée en pure Python

### Pourquoi est-ce important dans le domaine de la data

Principe Prog fonc	Avantage en Big Data
Immuabilité	Pas de conflit d'accès concurrent
Absence d'effets de bord	Facile à paralléliser
MapReduce	Approche naturellement fonctionnelle
Expressivité	Code plus concis et lisible

#### MapReduce

```
from functools import reduce
```

```
if __name__ == '__main__':
    # Appliquer une fonction sur chaque élément
    numbers = [1, 2, 3, 4, 5]
    mapped = map(lambda x: x ** 2, numbers) # [1, 4, 9, 16, 25]
    result = reduce(lambda x, y: x + y, mapped) # 1 + 4 + 9 + 16 + 25 = 55
    print(result) # Output: 55
```

#### MapReduce

def square(n):

```
return n ** 2

def sum_num(x, y):
    return x + y

mapped = map(square, numbers) # [1, 4, 9, 16, 25]

result = reduce(lambda x, y: sum_num(x,y), mapped) # 1 + 4 + 9 + 16 + 25 =

55

print(result) # Output: 55
```

# Programmation Fonctionnelle map()

En Python, la fonction map retourne un iterator.

Après avoir utiliser la fonction map, il n'est donc pas possible d'accéder directement à la collection retourner. Pour y accéder, il faut transformer l'iterator en liste, ou alors de faire une itération sur l'iterator.

```
if __name__ == '__main__':
    # Appliquer une fonction sur chaque élément
    numbers = [1, 2, 3, 4, 5]
    mapped = map(lambda x: x ** 2, numbers) # [1, 4, 9, 16, 25]
    # Convert to list
    result = list(mapped)
    print(result)
    #### OR ####
    # Print elements one by one
    for value in mapped:
        print(value)
```

map()

```
if __name__ == '__main__':
    # Appliquer une fonction sur chaque élément
    numbers = [1, 2, 3, 4, 5]
    mapped = map(lambda x: x ** 2, numbers) # [1, 4, 9, 16, 25]
    # Convert to list
    result = list(mapped)
    print(result)
    #### OR ####
    # Print elements one by one
    for value in mapped:
        print(value)
```

map() est consommé après l'itération, donc si nous réutilisons mapped après avoir fait list(mapped), le résultat sera vide. Une bonne pratique serait de toujours transformer en list si on veut réutiliser les données.