

Phase 1 : choix du jeu de données


- **Organisation** : groupes de trois ou quatre étudiants
- Chaque groupe doit choisir une **source de données** répondant aux critères suivants :
 - **Données issues du monde réel**, quelle que soit leur source (données perso, données d'entreprise, open data)
 - **Vous devrez justifier de votre source de données** et du caractère réel des données
 - Vous pouvez anonymiser les données
 - Votre jeu de données doit comporter au minimum :
 - 50 lignes
 - 3 dimensions
 - 2 mesures
- La source de données doit m'être préalablement soumise pour validation.

➤ Transformations :

- Vous pouvez effectuer des transformations de données si c'est nécessaire
- Vous devez alors préciser dans un document quelles transformations vous avez mises en place et avec quel outil technique (Power Query, Tableau Prep, Python, Excel, etc.)
- Vous êtes responsable du fait que vos transformations n'altèrent pas la signification des données

Date limite :
Lundi 15 décembre

Pour savoir si vos données peuvent être considérées comme réelles, consultez les exemples des diapos 3 et 4.



Phase 2 : remise finale

Date limite :
Mardi 24 décembre

Votre remise finale doit être composée de deux documents :

- Une présentation de votre jeu de données (document Word ou PowerPoint) indiquant :
 - Source précise
 - Le cas échéant, les transformations de données effectuées
 - Thème d'analyse choisi
 - Toute autre information que vous jugez utile
- Un **tableau de bord** construit avec Tableau (*.twbx). Ce tableau de bord doit comporter :
 - Une **Qualification des données**: renommage, distinction entre dimensions et mesures, formats par défaut, agrégations par défaut, hiérarchies, rôles géo, etc.
Tous les champs que vous laissez visibles doivent être bien paramétrés, même si vous ne les utilisez pas. Réciproquement, si un champ vous semble inutile ou dangereux, vous devez le masquer. L'idée est de faciliter la vie d'un analyste débutant qui voudrait ajouter de nouveaux graphiques sur vos données.
 - **Trois graphiques** de types différents ; ces graphiques doivent comporter un titre et toutes les informations nécessaires.
 - Au moins un **élément d'interactivité** (paramètre, filtre affiché / segment).
 - Un **calcul de ratio** (en formule ou en calcul de table) qui doit être utilisé sur au moins l'un de vos trois graphiques.
 - Pour chaque graphique, **une phrase** synthétisant la principale conclusion que, en tant qu'analyste de données, vous tirez du graphique.

N'ajoutez pas de graphique supplémentaire ; vous serez notés sur la qualité et non sur la quantité.

Ces données sont-elles réelles ? Exemple de source non fiable

Remote Work & Mental Health

Analyzing Mental Well-being in a Remote

Data Card Code (23)

About Dataset

As remote work becomes the norm, understanding its impact on employees' mental health is crucial. This dataset explores how working remotely affects stress levels, mental health conditions across various industries.

With 5,000 records collected from employees worldwide, this dataset provides valuable insights into key areas like work location (remote, hybrid, onsite), stress levels, access to mental health resources, and job satisfaction. It's designed to help researchers, HR professionals, and businesses assess the growing influence of remote work on productivity and well-being. 🌱 📊

5000 employés à l'échelle mondiale ?

Comment ont-ils été choisis ?

De quoi pourraient-ils être représentatifs ?

Provenance

PROVENANCE UPDATES

Auto Syncing: **Off**

Data will not continually sync with new notebook versions.

SOURCES

The dataset draws from a variety of sources to ensure a comprehensive understanding of the relationship between remote work and mental health. It incorporates responses from surveys distributed across social media platforms, professional networks, and online forums. These diverse channels helped capture a wide range of experiences and perspectives, enriching the dataset with valuable insights.

La source est « a variety of sources », mais, concrètement, aucune n'est indiquée

COLLECTION METHODOLOGY

Data collection involved designing a structured questionnaire that included both quantitative and qualitative questions. The survey was distributed digitally, allowing respondents to share their experiences regarding remote work's impact on their mental well-being. Responses were anonymized to maintain privacy. The methodology enables a thorough analysis of the challenges and benefits associated with remote work.

*Quel est le questionnaire ?
Quand a-t-il été envoyé ?
À qui ?*

Ces données sont-elles réelles ? Exemple de source fiable

US Accidents (2016 - 2023)

A Countrywide Traffic Accident Dataset (2016 - 2023)

[Data Card](#) [Code \(402\)](#) [Discussion \(44\)](#) [Suggestions \(0\)](#)

About Dataset

Description

This is a countrywide car accident dataset that covers **49 states of the USA**. The accident data were collected from **February 2016 to March 2023**, using multiple APIs that provide streaming traffic incident (or event) data. These APIs broadcast traffic data captured by various entities, including the US and state departments of transportation, law enforcement agencies, traffic cameras, and traffic sensors within the road networks. The dataset currently contains approximately **7.7 million** accident records. For more information about this dataset, please visit [here](#).

Information détaillée sur le périmètre, la représentativité et la méthode de collecte.

Lien valide pour les détails supplémentaires

Acknowledgments

Please cite the following papers if you use this dataset:

- Moosavi, Sobhan, Mohammad Hossein Samavatian, Srinivasan Parthasarathy, and Rajiv Ramnath. "[A Countrywide Traffic Accident Dataset.](#)", arXiv preprint arXiv:1906.05409 (2019).
- Moosavi, Sobhan, Mohammad Hossein Samavatian, Srinivasan Parthasarathy, Radu Teodorescu, and Rajiv Ramnath. "[Accident Risk Prediction based on Heterogeneous Sparse Data: New Dataset and Insights.](#)" In proceedings of the 27th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, ACM, 2019.

Référence aux articles publiés par l'auteur du jeu de données