

Machine & Deep Learning pour l'Ingénierie des Données


Philip Tchatchoua

2025-2026




Mastère Data Engineering & IA

Contenu du cours



Fondamentaux du
Machine & Deep
Learning



Extraction, préparation,
visualisation et
communication des
données



Modélisation
supervisée et non-
supervisée en Machine
Learning



Modélisation
supervisée et avancée
en Deep Learning

**Aujourd'hui, nous avons accès à plus de données que jamais auparavant.
La question est : comment en tirer le meilleur parti ?**



II. Extraction, préparation, visualisation et communication des données



Maîtriser l'extraction, la transformation et la préparation des données pour le Deep Learning

2.1

**Extraction de données
depuis différentes
sources**

2.2

**Méthodes de nettoyage
des données**

2.3


**Transformation des
données**

2.4

**Visualisation des
données et des
résultats**

Comprendre l'extraction de données

L'extraction de données est le **processus de collecte de données à partir d'une variété de sources** (fichiers, bases de données, API, web scraping, etc.) à des fins d'analyse ou de stockage.




Quelques exemples :

- Extraire les informations de contact des clients à partir de pages web et les stocker dans une feuille de calcul ou une base de données.
- Récupérer des csv, images, du texte ou des documents PDF pour les utiliser dans un projet de recherche.
- Collecter automatiquement des données à partir de capteurs et les télécharger sur une plateforme d'analyse de données.

Les différents types de données

Les **données structurées** sont organisées, formatées et facilement lisibles par les machines et les humains. Les données présentes dans les **feuilles de calcul** et les **bases de données SQL** sont des exemples de données structurées.



En revanche, les **données non structurées** ne sont **pas organisées selon un format spécifique** et sont plus difficiles à traiter et à stocker que les données structurées. Les documents texte, les images, les vidéos et les e-mails sont quelques exemples de données non structurées.

Les différents types de données

Données structurées	Données non structurées
Quantitatif : nombres, dates et chaînes de caractères	Qualitatif : images, audio, vidéo, fichiers de traitement de texte, feuilles de calcul
Schéma d'écriture	Schéma de lecture
Répresente 20% des données d'entreprise (Gartner)	Répresente 80% des données d'entreprise (Gartner)
Nécessite moins de stockage	Nécessite plus de stockage
Facilité d'utilisation des méthodes basées sur le langage SQL	Nécessite des outils plus complexes
Systèmes de gestion de bases de données relationnelles, entrepôts de données	Applications, bases de données NoSQL, lacs de données

Les différentes sources de données

Dans le contexte du Deep Learning, les données constituent le fondement de la construction et de l'entraînement des modèles. Les principales sources de données les plus couramment utilisées sont :

1. **Fichiers plats** : Formats simples comme CSV, TSV ou JSON, largement utilisés pour stocker et partager des données tabulaires.
2. **Bases de données relationnelles (SQL)** : Structures relationnelles organisées en tables, idéales pour des requêtes complexes et des systèmes organisés.
3. **Bases de données NoSQL** : Parfaites pour les données non structurées ou semi-structurées, souvent utilisées dans des applications modernes.
4. **APIs** : Interfaces fournissant des données dynamiques via des services web, notamment pour des cas comme les données météorologiques, les réseaux sociaux ou les services financiers.
5. **Données publiques (open data)** : Jeux de données disponibles publiquement à des fins de recherche ou d'analyse.
6. **Flux en temps réel** : Données collectées en direct depuis des capteurs IoT, des systèmes financiers ou des applications métiers.

Principaux challenges de l'extraction de données

Problèmes liés à la qualité des données : données inexactes, incomplètes ou dupliquées

Contraintes techniques : limites de taux d'API, gestion des volumes de données importants

Considérations légales et éthiques : réglementation sur la protection des données (anonymiser, minimiser, consentement, revues de conformité), considerations éthiques du web scraping

Gestion des données non structurées : textes, images, emails, audios, videos et autres données non tabulaires



II. Extraction, préparation, visualisation et communication des données



Maîtriser l'extraction, la transformation et la préparation des données pour le Deep Learning

2.1

**Extraction de données
depuis différentes
sources**

2.2

**Méthodes de nettoyage
des données**

2.3

**Transformation des
données**

2.4

**Visualisation des
données et des
résultats**

Connaitre les données

Une fois les données collectées, l'étape précédant le nettoyage et la transformation des données consiste à explorer les données. Explorer les données peut impliquer de nombreuses sous-tâches, telles que :

1. Discuter du projet avec des experts du domaine / lire la documentation sur les données
2. Résumer les données collectées à l'aide de méthodes statistiques
3. Visualiser les données collectées à l'aide de tracés et de graphiques
4. Sélectionner les variables à utiliser comme entrées et sorties pour le modèle prédictif

Les informations connues sur les données seront utilisées plus tard pour sélectionner et configurer les méthodes de préparation des données.

Les méthodes statistiques, telles que les statistiques descriptives, peuvent être utilisées pour déterminer si des opérations de mise à l'échelle peuvent être nécessaires.

Les tracés et les statistiques par paires peuvent être utilisés pour déterminer si les variables sont liées, et si oui, dans quelle mesure, ce qui permet de savoir si une ou plusieurs variables sont redondantes ou non pertinentes pour la variable cible.

Ainsi, il peut y avoir beaucoup d'interaction entre la définition du problème et la préparation des données.

Qu'est-ce que le data cleaning ?

Le **data cleaning** ou nettoyage des données consiste à **corriger les données afin d'en faciliter l'analyse et l'exploitation**. Ce qu'on appelle aussi « data cleansing » comprend la mise au bon format de l'ensemble de données, l'identification et le traitement des valeurs aberrantes (ou anomalies), la gestion des données manquantes et des doublons.

Les avantages du nettoyage des données


Le nettoyage des données est une **étape cruciale d'un projet data**, si ce n'est la plus importante. C'est souvent la première chose à faire lorsqu'on commence à exploiter des données.

Cette étape permet avant tout d'**apprendre à connaître ses données brutes**, en repérer les points d'intérêt, acquérir les premières intuitions sur l'utilisation future des données. C'est la base de toutes les analyses qui seront réalisées et les orientations prises pour la modélisation.

Gestion des valeurs manquantes

Les valeurs manquantes peuvent survenir pour diverses raisons, telles que des erreurs lors de la collecte de données ou des informations non rapportées. Les approches pour traiter ces valeurs incluent :

- **Suppression des lignes ou des colonnes** : Si le pourcentage de valeurs manquantes est très élevé, il peut être judicieux de supprimer les lignes ou colonnes concernées
- **Imputation des valeurs manquantes** : Remplacement des valeurs manquantes par une valeur estimée, comme la moyenne, la médiane, une valeur predictive ou des algorithmes d'imputations avancés



ID	Name	Email	Amount	City
1	John Doe	john@example.com	\$100	New York
2	Jane Smith	jane@example.com	\$150	
3	Mike Brown	mike@example	\$200	Los Angeles
4	Emma Green	emma@example.com	two hundred fifty	Chicago
5	Linda Blue	linda@example.com	\$250	

ID	Name	Email	Amount	City
1	John Doe	john@example.com	\$100	New York
2	Jane Smith	jane@example.com	\$150	San Francisco
3	Mike Brown	mike@example.com	\$200	Los Angeles
4	Emma Green	emma@example.com	\$250	Chicago

Gestion des doublons

Les données dupliquées (ou doublons) gonflent artificiellement les statistiques, comme les totaux et les moyennes. Les doublons dans les données peuvent ainsi biaiser les modèles, surtout si ces doublons représentent des observations sur-représentées.

ID	Name	Email	Purchase Date	Amount
1	John Doe	john@example.com	2023-06-15	\$100
2	Jane Smith	jane@example.com	2023-06-16	\$150
3	John Doe	john@example.com	2023-06-15	\$100
4	Mike Brown	mike@example.com	2023-06-17	\$200
5	Jane Smith	jane@example.com	2023-06-16	\$150


Remove Duplicates

ID	Name	Email	Purchase Date
1	John Doe	john@example.com	2023-06-15
2	Jane Smith	jane@example.com	2023-06-16
4	Mike Brown	mike@example.com	2023-06-17
6	Emma Green	emma@example.com	2023-06-18

Identification et traitement des valeurs aberrantes

Les anomalies ou valeurs aberrantes sont des **observations qui s'éloignent significativement des autres points** de données. Elles peuvent résulter d'**erreurs** ou représenter des **événements inhabituels**. Exemples :




- Données dans des unités différentes (prix en euros, dollars, yens, etc.)
- Différentes codifications pour la même entité (le Royaume-Uni représenté par UK, GB, RU)
- Formats divers pour la même entrée (dd/mm/aaaa, mm/dd/aa, etc.)
- Valeurs incohérentes (date de naissance d'un client en 1789)

Identification et traitement des valeurs aberrantes

Vérifier que chaque colonne ne contient **qu'un unique type de données** permet d'identifier rapidement les valeurs aberrantes et les sources de problème.

Le **traitement des anomalies dépend du contexte**. Elles sont supprimées si dues à des erreurs ou réajustées à une valeur acceptable lorsque possible. Si certaines anomalies sont corrigeables dès l'étape de collecte des données, c'est l'idéal afin d'éviter de répéter ce nettoyage en cas de mise à jour des données.

- Vérification orthographique, nettoyage des caractères non reconnus, uniformisation des données temporelles, uniformisation des données chiffrées



II. Extraction, préparation, visualisation et communication des données



Maîtriser l'extraction, la transformation et la préparation des données pour le Deep Learning

2.1

**Extraction de données
depuis différentes
sources**

2.2

**Méthodes de nettoyage
des données**

2.3

**Transformation des
données**

2.4

**Visualisation des
données et des
résultats**

Pourquoi préparer/transformer les données ?

Dans un projet de modélisation prédictive, comme la classification ou la régression, les données brutes ne peuvent généralement pas être utilisées directement. Cela est dû à des raisons telles que :

- Les algorithmes d'apprentissage automatique exigent que les **données soient des nombres**
- Certains algorithmes d'apprentissage automatique imposent des **exigences aux données**
- Il peut être nécessaire de **corriger le bruit statistique** et les **erreurs dans les données**
- Des **relations non linéaires complexes** peuvent être extraites des données

Par conséquent, les données brutes doivent être transformées avant d'être utilisées pour ajuster et évaluer un modèle d'apprentissage automatique.

Comment transformer les données ?

Les méthodes de transformation à appliquer sur les données sont choisies en fonction de la cartographie des données. Les données peuvent être enrichies, scindées, fusionnées ou filtrées.



Filtration

Sélection d'un sous-ensemble de données en fonction de critères spécifiques (agrégation ou sous-échantillonnage).



Enrichissement

Ajouter de nouvelles informations ou de la valeur aux données existantes (pivotement, discrétisation, augmentation).



Scission

Décomposer des données complexes en parties plus simples.




Fusion

Combiner des données provenant de différentes sources sur la base d'un attribut commun.


Discrétisation (binning, bucketing)

La discrétisation est le fait de convertir les caractéristiques numériques en caractéristiques nominales. Elle est utilisée pour simplifier l'exploitation des données dans certains types d'algorithmes.

Prenant un exemple sur les prix des maisons suivant la latitude. On ne peut pas trouver une fonction linéaire entre la latitude et le prix d'une maison, mais on sait que l'emplacement où cette maison se trouve affecte son prix.



VS



Binarisation

Il existe des cas où on n'a pas besoin des fréquences (nombre d'occurrences) d'une caractéristique pour créer un modèle; on a besoin seulement de savoir si cette caractéristique a apparue une fois au moins pour un échantillon. Dans le cas général, on veut vérifier si la fréquence a dépassé un certain seuil a ou non. Dans ce cas, on binarise les valeurs de cette caractéristique.

$$x' = \begin{cases} 1 & \text{si } x > a \\ 0 & \text{sinon} \end{cases}$$

Par exemple, pour construire un système de recommandation de chansons, il faut savoir si une personne est intéressée ou a écouté une chanson / un artiste / un genre en particulier. Il faudra considérer à la fois le nombre de fois qu'une chanson / un artiste / un genre a été écouté, et les différentes chansons que cette personne a écoutées.


Données déséquilibrées

Dans la classification, les données d'entraînement peuvent avoir des classes avec des proportions asymétriques. Les classes qui constituent une grande (petite) proportion de données sont appelées classes majoritaires (minoritaires) respectivement. Le degré de déséquilibre peut aller de léger à extrême.

Degré de déséquilibre	Proportion de la classe minoritaire
Léger	20-40% des données
Modéré	1-20% des données
Extrême	<1% des données

Données déséquilibrées


Par exemple, dans le cas de la détection de fraude, les cas positifs (il y a un fraude) sont rares par rapport au cas négatif (pas de fraude).



Lors de la phase d'entraînement, le système va prendre plus de temps à apprendre le cas négatif (pas de fraude) que le cas positif.

Sous-échantillonnage

Le sous-échantillonnage équilibre le jeu de données en réduisant la taille de la classe majoritaire. Cette méthode est utilisée lorsque la quantité de données est suffisante, donc on peut supprimer des échantillons de la classe majoritaire au hasard. Cela peut aider le système à converger rapidement et, aussi, préserver l'espace de stockage du modèle généré.



Sur-échantillonnage


Le sous-échantillonnage équilibre le jeu de données en augmentant la taille de la classe minoritaire. Cette méthode est utilisée lorsque la quantité de données est insuffisante. On peut augmenter la taille de la classe minoritaire en utilisant plusieurs techniques : réplication aléatoire des échantillons de la classe minoritaire, techniques de bootstrap, SMOTE (Synthetic Minority Over-Sampling Technique).

Normalisation / Standardisation des données

La mise à l'échelle des données appartient à un groupe de procédures de **normalisation/standardisation** des données qui visent à améliorer la qualité d'un ensemble de données en réduisant les dimensions et en évitant la situation où certaines valeurs surpondèrent d'autres.

La mise en échelle min-max transforme chaque valeur numérique x vers une autre valeur $x' \in [0,1]$ en utilisant la valeur minimale et la valeur maximale dans les données. Cette normalisation conserve la distance proportionnelle entre les valeurs d'une caractéristique.

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$



Encodage des variables catégorielles

L'encodage des variables catégorielles est une étape importante dans la préparation des données pour le Deep Learning. Les deux méthodes d'encodage les plus couramment utilisées sont le **Label Encoding** et le **One-Hot Encoding**.

Label Encoding

Food Name	Categorical #	Calories
Apple	1	95
Chicken	2	231
Broccoli	3	50

Attribue un entier unique à chaque catégorie.



One Hot Encoding

Apple	Chicken	Broccoli	Calories
1	0	0	95
0	1	0	231
0	0	1	50

Crée une nouvelle variable binaire pour chaque catégorie de la variable initiale

II. Extraction, préparation, visualisation et communication des données



Maîtriser l'extraction, la transformation et la préparation des données pour le Deep Learning

2.1

**Extraction de données
depuis différentes
sources**

2.2

**Méthodes de nettoyage
des données**

2.3


**Transformation des
données**

2.4

**Visualisation des
données et des
résultats**

Pourquoi visualiser ?

- **Exploration des données** : Identifier les biais, les corrélations, les distributions (ex : déséquilibre de classes, anomalies, etc.).
- **Débogage des modèles** : Analyser les courbes d'apprentissage, les erreurs de prédiction (ex : *overfitting*).
- **Communication** : Rendre les résultats techniques accessibles à des non-experts (ex : rapports clients).



Exemple : Visualisation de la distribution des pixels dans un dataset d'images médicales* pour détecter des artefacts

*<https://www.quantmetry.com/blog/deep-learning-diagnostic-imagerie-medicate/>

Outils et bibliothèques

Les outils de base



seaborn


Matplotlib/Seaborn : Créer des graphiques statiques (histogrammes, scatter plots, heatmaps).



Pandas : Générer des visualisations rapides via `df.plot()`.




Plotly : Visualisations interactives (zooms, survol de points).



Exemple : Utiliser Seaborn pour afficher une matrice de corrélation* d'un dataset

*<https://moncoachdata.com/tutos/diagrammes-matriciels/>

Outils et bibliothèques



Les outils avancés



TensorBoard

TensorBoard : Suivre des métriques en temps réel (loss, accuracy) pendant l'entraînement de modèles TensorFlow/PyTorch.



MLflow : Comparer visuellement les performances de plusieurs runs (hyperparamètres, métriques).



Streamlit

Streamlit : Créer des dashboards interactifs pour présenter des résultats et explorer les prédictions des modèles.

Exemple : Utiliser TensorBoard* pour analyser la convergence d'un RNA.


*<https://inside-machinelearning.com/graphiques-elegants-tensorboard/>

Techniques de visualisation des données

Données structurées


Heatmaps/Cluster maps :

Identifier des corrélations
entre variables.




Violin/Box/Swarm plots :

Comparer des
distributions multi-
classes.



Projection en 2D/3D :

Techniques de réduction
de dimension (PCA, t-
SNE, UMAP).



*<https://medium.com/@ankitjaat24u/swarm-plot-vsvoilonplot-vs-boxplot-8ca0f2849936/>

*<https://meta.caspershire.net/umap/>




Techniques de visualisation des données

Données non structurées

Images : Activation maps (Grad-CAM) pour interpréter les prédictions d'un CNN.

Texte : Word clouds pour les fréquences de mots, ou embeddings projetés avec UMAP.

Séries Temporelles : Graphiques interactifs avec Plotly pour explorer des tendances.



Exemple : Grad-CAM appliqué à un modèle de classification pour identifier les régions influençant une prédiction chien vs chat.


* <https://medium.com/@lokwa780/grad-cam-63dfc305f45d>

* <https://datascientest.com/grad-cam>


Visualisation des résultats d'apprentissage

Courbes d'apprentissage

- Identifier le surapprentissage (*validation loss* qui diverge de la *training loss*).
- Comparer les performances de différents modèles (ex : Random Forest vs CNN).



without dropout



10% dropout

Exemple : Comparaison des courbes de loss d'un modèle avant et après régularisation (Dropout)


*https://www.researchgate.net/figure/Drop-out-effect-on-the-loss-function-during-training-in-parallel-The-model-with-drop-out_fig4_353997562/

Visualisation des résultats d'apprentissage

Matrices de confusion et métriques

- Visualiser les classes mal classées (ex : faux positifs en détection d'objets).
- Utiliser des rapports de classification (heatmaps de précision/rappel, courbes ROC, etc.).

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specifitivity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TN + FP + FP + FN)}$




Exemple : Matrice de confusion d'un modèle de détection de fraudes avec un déséquilibre classe majoritaire (99% de non-fraudes).

*<https://datascientest.com/matrice-de-confusion>

*<https://penseeartificielle.fr/detection-de-fraude-temps-reel-python-lightgbm/>

Contenu du cours



Fondamentaux du
Machine & Deep
Learning



Extraction, préparation,
visualisation et
communication des
données



Modélisation
supervisée et non-
supervisée en Machine
Learning



Modélisation
supervisée et avancée
en Deep Learning