


NATURAL LANGUAGE PROCESSING

INTRODUCTION À IA ET ML


Sarah Malaeb
2025-26

QU'EST-CE QUE L'INTELLIGENCE ARTIFICIELLE ?

- L'IA est un domaine de l'informatique qui se concentre sur la création de machines capables d'effectuer des tâches qui nécessitent généralement l'intelligence humaine
- Quelques exemples : la perception visuelle, la reconnaissance vocale, la prise de décision et la traduction de langues...



QUELQUES SOUS-DOMAINES DE L'IA



QUELQUES SOUS-DOMAINES DE L'IA

- En tant que discipline scientifique, l'IA comprend plusieurs approches et techniques, telles que :
 - **l'apprentissage automatique** : dont l'apprentissage profond et l'apprentissage par renforcement sont des exemples spécifiques
 - **le raisonnement automatique** : qui comprend la planification, la programmation, la représentation des connaissances et le raisonnement, la recherche et l'optimisation
 - **la robotique** : qui comprend le contrôle, la perception, les capteurs et les actionneurs, ainsi que l'intégration de toutes les autres techniques dans des systèmes cyber-physiques (système où des éléments informatiques collaborent pour le contrôle et la commande d'entités physiques).

DOMAINES D'APPLICATION DE L'IA


- Santé et médecine
- Automobile
- E-commerce
- Jeux video
- Réseaux sociaux
- Robotique
- Education
- Surveillance
- Etc.

QUELQUES EXEMPLES DE L'IA

- Santé et médecine : recommandation des traitements personnalisés, ...
- Automobile : voiture autonome, ...
- E-commerce : système de recommandation de produits, ...
- Jeux video : réaction automatique aux actions du joueur par simulation de leurs comportements...
- Réseaux sociaux : identification automatique de contenu inapproprié, ...
- Robotique : robots de livraison autonome, robots chirurgiens, ...
- Education : personnalisation automatique des cours (e.g. Duolingo), ...
- Surveillance : détection d'objets et de comportements suspects dans les vidéos en temps réel, ...
- Etc.


IA VS. DATA SCIENCE VS. ML VS. DL

- IA : Intelligence artificielle, simulation de l'intelligence humaine.
- ML : Apprentissage automatique, modèles pour prédiction.
- DL : Apprentissage profond, réseaux imitant le cerveau.
- Data Science : Science des données, décisions informées.





MACHINE LEARNING = APPRENTISSAGE AUTOMATIQUE

- L'approche de l'apprentissage automatique dans laquelle un système est formé sur des données et utilise ces informations pour faire des prédictions ou prendre des décisions.




APPRENTISSAGE AUTOMATIQUE SUPERVISÉ

- C'est une approche de l'apprentissage automatique où un modèle est formé à partir de données étiquetées, avec des entrées et des sorties connues
- Il est utilisé afin de faire des prédictions ou de classer de nouvelles données en se basant sur les patterns identifiés dans les exemples d'entraînement.
- On distingue principalement deux types de problèmes :
 - **Classification**
 - Le but de ce modèle est de déterminer une catégorie - c'est une chose ou une autre. Le modèle est entraîné pour classer l'ensemble de données.
 - **Régression**
 - Ce modèle est créé dans le but de trouver une valeur. À l'aide des données, l'algorithme peut trouver des associations entre deux variables quelconques et prédire le résultat en conséquence.




APPRENTISSAGE AUTOMATIQUE NON SUPERVISÉ

- C'est une méthode de l'apprentissage automatique où un modèle explore des données non étiquetées.
- Il permet de découvrir des structures, des relations ou des regroupements intrinsèques, permettant ainsi d'extraire des informations significatives sans la présence d'annotations préalables.
- Une technique très répandue: Le **clustering**
 - permettant de regrouper des chaînes de données par distance ou par similarité.



APPRENTISSAGE PAR RENFORCEMENT

- C'est une approche où un agent apprend à prendre des actions dans un environnement pour maximiser une récompense cumulative.
- L'agent explore différentes stratégies en interagissant avec l'environnement, en apprenant quelles actions mènent à des récompenses positives et en ajustant ses choix en conséquence.



CYCLE DE VIE D'UN PROJET DE SCIENCES DE DONNÉES

Le cycle de vie d'un projet de science des données comprend plusieurs étapes :



CYCLE DE VIE D'UN PROJET DE SCIENCES DE DONNÉES

Le cycle de vie d'un projet de science des données comprend plusieurs étapes :

1. **Compréhension du problème et définition des objectifs** : comprendre clairement le problème et définir les objectifs spécifiques du projet.
2. **Collecte des données** : identifier les sources de données pertinentes pour le projet et rassembler les données nécessaires.
3. **Nettoyage et exploration des données** : nettoyer les données en éliminant les valeurs aberrantes, les doublons et en gérant les valeurs manquantes. Ensuite, explorer les données pour en comprendre la structure et les relations entre les variables.

CYCLE DE VIE D'UN PROJET DE SCIENCES DE DONNÉES

- 4. Préparation des données** : transformer les données en un format approprié pour l'analyse par normalisation, transformation de variables, encodage de catégories, etc.
- 5. Modélisation** : Choisir le modèle de ML appropriées en fonction des objectifs (régression, classification, clustering, etc) et entraîner le sur les données d'entraînement.
- 6. Évaluation** : Évaluer la performance des modèles utilisés, en utilisant les données de test, en prenant en compte des métriques appropriées telles que la précision...
- 7. Optimisation** : optimisez les modèles en ajustant leurs hyperparamètres, afin de les rendre plus performants.

CYCLE DE VIE D'UN PROJET DE SCIENCES DE DONNÉES


8. **Interprétation des résultats** : Analyser les résultats des modèles, et identifier les facteurs ayant le plus d'impact sur les prédictions.
9. **Communication des résultats** : Présenter les résultats de manière claire en assurant qu'elles soient compréhensibles même pour les non-experts.
10. **Déploiement** : une fois le modèle est prêt à être utilisé dans un environnement de production, déployer-le afin de rendre disponible aux clients pour l'utilisation.
11. **Maintenance** : Surveiller en continu la performance des modèles en production, et les mettre à jour si nécessaire.

QU'EST-CE QUE L'ANALYSE DE DONNÉES?

- L'analyse des données est le domaine de la collecte et de la compréhension des données.
- C'est la science de l'analyse de données brutes pour en tirer des conclusions.
- Bon nombre des techniques et processus d'analyse des données ont été automatisés en processus mécaniques et algorithmiques qui traitent les données brutes pour une consommation humaine.

STADE DE L'ANALYSE DE DONNÉES DANS LE PROCESSUS DE MACHINE LEARNING

- Processus de Machine Learning:



Collecte, Exploration et
Prétraitement de données

L'ANALYSE DE DONNÉES

Comment prétraiter les données, les explorer à l'aide de statistiques descriptives et de visualisations, et les interpréter??

C'EST QUOI LE DATASET ?

- Un ensemble de données contient une énorme quantité de données.
- Plus l'ensemble de données est grand et diversifié, meilleure sera la capacité du modèle à prédire les résultats les plus précis possibles.
- Vous devez être capable d'utiliser l'ensemble de données de manière judicieuse afin de pouvoir à la fois choisir un modèle (d'apprentissage automatique) et le former, mais aussi pour pouvoir tester la qualité de ce modèle.
- Pour cela, vous devez savoir échantillonner, nettoyer et découper les données.

DATASET ÉTIQUETÉ OU NON ÉTIQUETÉ

- Un jeu de données **étiqueté** est constitué d'exemples de données associés à des labels ou des catégories prédéfinies, permettant ainsi à un modèle d'apprentissage automatique de généraliser à de nouvelles données en apprenant les relations entre les entrées et les labels.
- Un jeu de données **non étiqueté** ne comporte pas de labels préalables, ce qui requiert des méthodes d'analyse spécifiques pour découvrir des structures, des tendances ou des regroupements inhérents aux données.

EXEMPLE D'UN ENSEMBLE DE DONNÉES ÉTIQUETÉES


		Inputs / Entrées Variables Indépendantes			Output / Sortie Variable Dépendante TARGET/ CIBLE
		FEATURES			
EXAMPLES	Runner ID	Run	Runner time	Elevation	Fun
	AV3DE	Boston Marathon	03:40:32	1,300ft	Low
	X8KGF	Seattle Oktoberfest 5k	00:35:40	0ft	High
	BH9IU	Houston half-marathon	02:01:18	200ft	Medium
					LABELS

Instance Observation

EXEMPLE D'UN ENSEMBLE DE DONNÉES NON ÉTIQUETÉES

Customer Id	Age	Edu	Years Employed	Income	Card Debt	Other Debt	Address	DebtIncomeRatio
1	41	2	6	19	0.124	1.073	NBA001	6.3
2	47	1	26	100	4.582	8.218	NBA021	12.8
3	33	2	10	57	6.111	5.802	NBA013	20.9
4	29	2	4	19	0.681	0.516	NBA009	6.3
5	47	1	31	253	9.308	8.908	NBA008	7.2
6	40	1	23	81	0.998	7.831	NBA016	10.9
7	38	2	4	56	0.442	0.454	NBA013	1.6
8	42	3	0	64	0.279	3.945	NBA009	6.6
9	26	1	5	18	0.575	2.215	NBA006	15.5
10	47	3	23	115	0.653	3.947	NBA011	4
11	44	3	8	88	0.285	5.083	NBA010	6.1
12	34	2	9	40	0.374	0.266	NBA003	1.6

TYPES DES DONNÉES



A QUOI SERT LA COLLECTE DES DONNÉES?

- La collecte des données consiste à rassembler et à obtenir des informations brutes à partir de diverses sources, telles que des bases de données, des fichiers, des capteurs, des enquêtes ou des API, en vue de constituer un ensemble de données pertinent pour une analyse ou un projet spécifique.



A QUOI SERT L'EXPLORATION DES DONNÉES ?

- L'exploration des données, également appelée exploration de données, implique l'analyse et l'examen approfondis du jeu de données collecté.
- L'objectif est de comprendre la structure des données, les tendances, les relations entre les variables et d'identifier les caractéristiques importantes, les valeurs aberrantes potentielles ou les valeurs manquantes.
- En python, il existe plusieurs libraires et techniques pour explorer les données. On en cite quelques-unes.

COMMENT EXPLORER LES DONNÉES ?


- Exploratory Data Analysis (EDA) : L'EDA est une approche holistique pour explorer les données. Elle implique la création de graphiques, de tableaux de fréquence, de matrices de corrélation, de diagrammes de dispersion et d'autres outils pour découvrir des schémas, des tendances et des valeurs aberrantes.
- Analyses univariées et multivariées : Les analyses univariées se concentrent sur une seule variable à la fois, tandis que les analyses multivariées explorent les relations entre plusieurs variables simultanément pour identifier des corrélations et des interactions.
- Analyse de corrélation : Vous pouvez utiliser des graphiques de corrélation comme les matrices de corrélation et les heatmap pour comprendre les relations linéaires entre différentes variables.

COMMENT EXPLORER LES DONNÉES?

- Quelques librairies python utiles :
 - **Pandas** : La bibliothèque Pandas est largement utilisée pour manipuler et analyser des données tabulaires. Vous pouvez utiliser des fonctions comme `head()`, `describe()`, `info()`, et `value_counts()` pour obtenir un aperçu des données, des statistiques sommaires et des informations sur les types de données.
 - **Matplotlib** et **Seaborn** : Ces bibliothèques permettent de créer des graphiques et des visualisations pour explorer la distribution des données, les relations entre les variables et les tendances.
 - **Plotly** : Plotly est une autre bibliothèque de visualisation qui permet de créer des graphiques interactifs pour explorer les données sous différents angles.
 - **Scikit-Learn** : En plus d'être une bibliothèque pour la création de modèles, Scikit-Learn offre des outils pour la préparation et la visualisation des données. Par exemple, vous pouvez utiliser `train_test_split()` pour diviser vos données en ensembles d'entraînement et de test.

A QUOI SERT LE PRÉTRAITEMENT DES DONNÉES?


- Le prétraitement des données, quant à lui, fait référence aux étapes nécessaires pour préparer les données en vue d'une analyse ou d'un modèle d'apprentissage automatique.
- Cela peut inclure :
 - le nettoyage des données
 - en supprimant les valeurs aberrantes
 - et en gérant les valeurs manquantes,
 - la normalisation ou la standardisation des variables,
 - la transformation des données catégorielles en format numérique,
 - et d'autres manipulations visant à rendre les données cohérentes et appropriées pour l'analyse ultérieure.



NETTOYAGE DE DONNÉES


- Il permet d'identifier et de corriger les erreurs, les doublons et les données non pertinentes d'un ensemble de données brut.
- Il fait partie du processus de préparation des données.
- Il permet d'obtenir des données précises et défendables, qui génèrent des visualisations, des modèles et des décisions commerciales fiables.

DATA CLEANING CHECKLIST



ÉQUILIBRE DES DONNÉES

- Les données déséquilibrées ne sont pas toujours une mauvaise chose, et dans les ensembles de données réels, il existe toujours un certain degré de déséquilibre. Il ne devrait pas y avoir d'impact important sur les performances de votre modèle si le niveau de déséquilibre est relativement faible.
- Techniques pour convertir un ensemble de données déséquilibré en un ensemble de données équilibré :



MISE À L'ÉCHELLE DES DONNÉES

- De nombreux algorithmes d'apprentissage automatique tentent de trouver des tendances dans les données en comparant les caractéristiques des points de données.
- Cependant, lorsque l'algorithme compare les points de données, la caractéristique ayant une échelle plus grande domine complètement les autres.
- C'est pourquoi il est important de mettre à l'échelle les données.

MISE À L'ÉCHELLE DES DONNÉES

• Deux techniques couramment utilisées pour la mise à l'échelle :

- **Normalisation**


- Garantit que toutes les caractéristiques auront la même échelle exacte, mais ne gère pas bien les valeurs aberrantes.

- **Standardisation**

- Gère les valeurs aberrantes, mais ne produit pas de données normalisées avec la même échelle exacte.

Exemple par normalisation min-max

$$\frac{value - min}{max - min}$$




Exemple par normalisation Z-score

$$z = \frac{x - \mu}{\sigma}$$

ENCODAGE DES DONNÉES

- L'encodage des données en résolution de problèmes de ML consiste à convertir les caractéristiques ou variables catégorielles en une forme numérique compréhensible par les algorithmes d'apprentissage automatique, permettant ainsi de traiter ces données dans des modèles.
- Cela facilite l'intégration de données catégorielles dans les processus d'entraînement et de prédiction tout en évitant les ambiguïtés liées aux valeurs non numériques.

PARTITIONNEMENT DES DONNÉES



TP EDA

TP sur l'analyse exploratoire des données.

- Points Bonus/Malus