

NATURAL LANGUAGE PROCESSING

INTRODUCTION AU NLP (TRAITEMENT AUTOMATIQUE DU LANGAGE NATUREL)



Sarah Malaeb
2025-26

NATURAL LANGUAGE PROCESSING (NLP)

Traitement Automatique du Langage Naturel

Le NLP est un domaine interdisciplinaire entre l'informatique et la linguistique.



- permet aux ordinateurs de comprendre le langage humain.
- sous-domaine de l'Intelligence Artificielle (IA) qui vise à doter les machines de la capacité de comprendre, d'interpréter et de générer du langage humain.
- Objectif : rendre les machines capables de traiter le langage de manière intelligente, ce qui relève du but plus large de l'IA : simuler l'intelligence humaine.



CLASSIC NLP VS. AI-BASED NLP


Aspect	Le NLP classique	Le NLP assisté par l'IA (moderne)
Techniques	Règles, linguistique, dictionnaires	Apprentissage automatique, apprentissage profond, transformeurs
Implication de l'IA	Pas nécessairement	Composant central
Objectif	Traitement du langage	Compréhension et génération intelligente du langage

Le NLP classique peut être basé sur des règles ou des statistiques, sans algorithmes d'apprentissage. e.g.
context-free grammar parsing (analyse de grammaires hors contexte),
stemming/lemmatization (racinisation/lemmatization).




Le NLP moderne : repose souvent sur l'IA, notamment l'apprentissage automatique et l'apprentissage profond. e.g.
BERT, GPT, LSTM : modèles NLP assistés par l'IA.

NLP VS. IA GÉNÉRATIVE



EVOLUTION DU NLP



- Phonologie : étudie les motifs présents dans les sons et la parole comme entité physique.
- Pragmatique : étudie les différents usages du langage.
- Morphologie : analyse la structure des mots et les relations systématiques entre eux.
- Syntaxe : s'intéresse à la structure des phrases.
- Sémantique : traite du sens littéral des mots, phrases et énoncés.

IMPORTANCE DU NLP POUR LE WEB

Le contenu du web est majoritairement textuel.

Le langage naturel est le principal moyen d'expression en ligne.

La majorité de l'information en ligne est non structurée : blogs, forums, réseaux sociaux, emails, avis produits, articles d'actualité.

Le NLP est essentiel pour comprendre, organiser et donner du sens à ces textes afin d'alimenter :

- les moteurs de recherche, les chatbots, les systèmes de recommandation, la traduction automatique, l'analytique à grande échelle.

EXEMPLES D'APPLICATIONS DU NLP

Recherche d'information
Recherche documentaire



Analyse sentimentale



Information Extraction



Extraction
automatique
d'information

Traduction
automatique



**Natural
Language
Processing**

QuestionAnswering



Questions-Réponses
automatique

EXEMPLES D'APPLICATIONS DU NLP

Top Natural Language Processing Examples Businesses are Employing



Smart
Assistants



Search
Results



Predictive
text



Language
Translations



Digital
Phone Calls



Text
Analytics



Virtual
Assistants



Detecting
Duplications



Social Media
Monitoring



Marketing
Strategies



Descriptive
Analytics



Automatic
Insights

DONNÉES TEXTUELLES

Données exprimées en mots, phrases ou caractères.

e.g. emails, rapports, publications (posts) sur les réseaux sociaux, articles, or avis.

La plupart des données textuelles sont non structurées car :

- Elles n'ont pas de schéma fixe comme des lignes et des colonnes.
- Leur sens et leur structure doivent être interprétés ou extraits (par ex. phrases, entités, sentiments).

DONNÉES TEXTUELLES

Les données textuelles peuvent être partiellement structurées dans certains cas :

E.g.

Fichiers CSV avec une colonne “Commentaires” → la colonne elle-même contient du texte, mais elle est stockée dans un tableau.

Ce sont des données structurées avec du contenu non structuré :

- La structure CSV elle-même est une donnée structurée (colonnes et lignes).
- La colonne “Commentaires” contient des données textuelles, qui sont non structurées à l’intérieur du conteneur structuré.

Documents JSON avec des clés et valeurs → le contenu textuel est structuré via des paires clé-valeur.

Ce sont des données structurées avec du contenu non structuré :

- Les clés (nom, commentaire) fournissent la structure.
- La colonne “Commentaires” contient des données textuelles, qui sont non structurées à l’intérieur du conteneur structuré.

```
json
{
  "name": "Alice",
  "comment": "Loved the product, very useful"
}
```

Fichiers PDF → le contenu textuel est non structuré.

Texte brut, comme les emails, rapports ou publications sur les réseaux sociaux, est non structuré, mais le texte stocké dans des champs fixes ou des formats annotés peut être semi-structuré.

EXTRAIRE DE LA VALEUR (INSIGHTS) À PARTIR DES DONNÉES NON STRUCTURÉES

80–90 % des données mondiales sont non structurées.

Techniques telles que **NLP**, **text mining**, et **IA** sont essentielles pour en extraire des informations utiles.




Image source: <https://www.igneous.io/blog/structured-data-vs-unstructured-data>

ANALYSE DE DONNÉES TEXTUELLES

Comprendre comment analyser les données textuelles et appliquer des techniques de NLP.

Exemple pratique : nous allons commencer l'inspection avec <https://voyant-tools.org/>

FOUILLE DE TEXTES (TEXT MINING): MÉTHODOLOGIE D'ANALYSE DES DONNÉES UTILISANT LE NLP

Text mining est une méthodologie d'analyse des données qui utilise le NLP pour extraire des motifs (patterns) et des informations à partir des textes.

Text mining = méthodologie

NLP = techniques nécessaires pour le Text mining

Objectif : extraire des patterns/insights

- Text mining utilise le NLP pour découvrir de la connaissance (knowledge discovery), pas nécessairement comprendre ou générer du langage.

TP 01: VOYANT TOOLS

Activité individuelle

Explorer l'outil de text mining : **Analyser des textes avec Voyant Tools**

- Voyant is une plateforme web intégrant des méthodes de text mining et de visualisation basées sur le NLP.

Suivre l'exemple disponible sur GitHub :

<https://github.com/miriamposner/voyant-workshop/blob/master/investigating-texts-with-voyant.md>