

NATURAL LANGUAGE PROCESSING

PROCESSUS DU NLP

Sarah Malaeb
2025-26


RÉFÉRENCES PRINCIPALES DE CE COURS

Machine Learning A-Z, Kirill Eremenko, Hadelin de Ponteves, @SuperDataScience

PROCESSUS DU NLP

Le processus de traitement automatique du langage naturel comprend plusieurs étapes:

- Prétraitement et nettoyage des données
- Tokenisation
- Vectorisation avec des techniques d'embeddings, etc.
- Analyse, modélisation et évaluation




POURQUOI LE PRÉTRAITEMENT EST-IL NÉCESSAIRE EN NLP ?

Le langage humain est ambigu, désordonné et non structuré.

Les ordinateurs ne comprennent pas directement les mots ou la grammaire ; ils ont besoin de nombres.


Le prétraitement fait le pont :

- Nettoyer le texte (supprimer le bruit)
- Standardiser les mots (normalisation, lemmatisation, etc.)
- Convertir en vecteurs (TF-IDF, embeddings comme Word2Vec, BERT, etc.)




OBJECTIF PRINCIPAL DU PRÉTRAITEMENT EN NLP

Étapes du prétraitement des textes :



L'objectif principal du prétraitement en NLP est : Transformer le langage brut et non structuré en une représentation numérique propre qui peut être utilisée efficacement par des modèles de Machine Learning ou Deep Learning.

OBJECTIF PRINCIPAL DU PRÉTRAITEMENT EN NLP



NETTOYAGE DE DONNÉES

La 1ère étape en NLP consiste à nettoyer les données.

- Supprimer les caractères inutiles (ponctuation, chiffres)
- Convertir tout le texte en minuscules
- Supprimer les mots vides (stop words comme “le”, “et”, “un”) qui sont peu susceptibles d’être informatifs

Cette étape est importante pour améliorer la qualité des données et réduire le bruit.

- » Remove whitespaces
- » Remove HTML tags
- » Convert accented characters
- » Remove special characters
- » Remove words
- » Remove stop words



TOKENISATION

Les tokens sont les briques de base du langage.




Ils peuvent être : caractères, sous-mots, mots ou groupes de mots.

La tokenisation est **le processus qui consiste à découper un texte en unités plus petites appelées Tokens.**


Il existe plusieurs techniques de tokenisation, notamment :

- la tokenisation au niveau des mots, qui découpe le texte en mots individuels,
- la tokenisation au niveau des caractères, qui découpe le texte en caractères individuels.




La tokenisation est importante car elle permet de traiter le texte à un niveau plus fin et d'en extraire des caractéristiques significatives.



POS tagging




TOKENISATION



Par défaut, un token est souvent considéré comme un mot, mais en pratique, les tokens peuvent être :

- Word-level tokens:
 - Phrase: "NLP is powerful."
 - Tokens: ["NLP", "is", "powerful"]
- Subword tokens (used in BERT, GPT, etc.):
 - Mot: "unhappiness"
 - Tokens: ["un", "happi", "ness"]
- Multi-word tokens:
 - Expression: "New York City"
 - Token: ["New York City"]



TOKENISATION

La technique utilisée pour découper un texte en unités plus petites afin de pouvoir les traiter.





- **Lemmatisation et Racinisation (stemming) :**

Cela consiste à réduire les mots à leur forme racine pour les traiter.

- **Étiquetage morphosyntaxique (Part-of-Speech – POS tagging) :**

Cela consiste à marquer les mots en fonction de leur catégorie grammaticale.

Exemple : l'étiquetage POS associe à chaque mot son rôle (nom, verbe, adjectif, etc.) afin de capturer le sens grammatical.



TOKENISATION

Normalisation:

C'est le processus de standardisation des mots afin que le texte devienne cohérent et plus facile à analyser.

Objectif : créer une **représentation uniforme des mots** pour améliorer l'analyse textuelle et réduire le bruit.

Pourquoi ? **Le langage naturel est désordonné : un même sens peut apparaître sous de nombreuses formes** (ex. "Running", "runs", "ran").

La normalisation réduit cette variabilité afin que les modèles ne traitent pas ces mots comme totalement différents.

Étapes courantes de la normalisation :

- Passage en minuscules (Lowercasing) → ex. "Apple" → "apple"
- Expansion des contractions → ex. "don't" → "do not"
- Conversion des nombres → ex. "twenty-one" → "21"
- Suppression des accents → ex. "café" → "cafe"
- Stemming / Lemmatisation → ex. "running", "ran" → "run"

VECTORISATION

Après la tokenisation, l'étape suivante est la vectorisation : elle consiste à **convertir le texte en vecteurs numériques pouvant être utilisés comme entrée pour les modèles de Machine Learning**.


Il existe différentes approches, pas seulement les word embeddings..

Méthodes statistiques classiques :

- Sac de mots (Bag of Words – BoW) : compte des occurrences de mots. Exemple:
- TF-IDF (Term Frequency–Inverse Document Frequency): pondère les mots selon leur importance dans un corpus.
Exemple : les mots courants (“the”) obtiennent un poids faible, tandis que les mots rares mais distinctifs obtiennent un poids plus élevé.
- Embeddings (méthodes sémantiques):
- Word2Vec, GloVe, FastText: apprennent des vecteurs denses où les mots similaires sont proches dans l'espace.
- Contextual embeddings (BERT, SBERT, GPT): représentent les mots différemment selon le contexte.
Exemple: “Java” (le langage de programmation) $\neq$ “Java” (l'île indonésienne).

	the	red	dog	cat	eats	food
1. the red dog →	1	1	1	0	0	0
2. cat eats dog →	0	0	1	1	1	0
3. dog eats food →	0	0	1	0	1	1
4. red cat eats →	0	1	0	1	1	0

VECTORISATION



VECTORISATION

Word2vec

Utilise un modèle de réseau de neurones pour apprendre les associations de mots à partir d'un large corpus de texte.

GloVe

Algorithme non supervisé qui a déjà été entraîné sur un vaste corpus afin d'apprendre la proximité entre les mots, de reconnaître la matrice d'inclusion des mots et de représenter les mots comme proches ou éloignés les uns des autres.

TF-IDF

TF: Term Frequency

fréquence d'un mot dans un document

IDF: inverse document frequency

importance d'un mot dans le corpus
(réduit le poids des mots fréquents)

→ Résultat : les mots rares mais distinctifs ont plus de poids.

$$TF(t, d) = \frac{(\text{Number of occurrences of term } t \text{ in document } d)}{(\text{Total number of terms in the document } d)}$$

$$IDF(t, D) = \log_e \frac{(\text{Total number of documents in the corpus})}{(\text{Number of documents with term } t \text{ in them})}$$

$$TF-IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

$$TFIDF_{t,d,D} = TF_{t,d} \times IDF_{t,D}$$

Importance d'un terme
t dans un document d

Fréquence d'un terme
t dans un document d

Importance du terme
t dans l'ensemble des
documents D

- Frequent words in a document have higher TF. Common words across many documents (like “the”, “and”, “is”) get lower IDF, reducing their overall weight.
- Rare, more distinctive words get higher IDF, increasing their importance.
- TF-IDF combines both: common words get lower weight and rare but meaningful words get higher weight.
- >>> Meaningful words get higher weight
- TF-IDF does NOT understand or calculate the meaning of words.
- TF-IDF is purely statistical.
- It assigns higher weight to words that are rare in the corpus but frequent in a document.
- “Meaningful” in this context just means: a word that is distinctive or informative for that document, not semantically meaningful in a human or linguistic sense.

Utilisation d'auto-encodeurs, tels que des techniques basées sur les transformeurs


Par exemple:

BERT (Bidirectional Encoder Representations from Transformers)

GPT (Generative Pretrained Transformer)

DeBERTa (Decoding-enhanced BERT with Disentangled Attention)

T5 (Text-to-Text Transfer Transformer)



MODÉLISATION ET EVALUATION

Après la vectorisation, l'étape finale consiste à entraîner et évaluer des modèles de machine learning sur les données.

Les modèles couramment utilisés pour les tâches de NLP incluent : Naive Bayes, Support Vector Machines (SVM), and Recurrent Neural Networks (RNNs)...

Le choix du modèle dépend de la tâche spécifique et des données disponibles.

PLUSIEURS TECHNIQUES DE MACHINE LEARNING ET DEEP LEARNING UTILISÉES POUR LE NLP

- **Naive Bayes Classifier (Classifieur de Naive Bayes)** : C'est un algorithme probabiliste simple, couramment utilisé pour les tâches de classification de texte telles que l'analyse de sentiments, la détection de spam et la modélisation de sujets.
- **Support Vector Machines SVM (Machines à vecteurs de support)** : Les SVMs sont couramment utilisés pour la classification de texte et les tâches d'analyse de sentiments. Ils fonctionnent en trouvant un hyperplan qui sépare les points de données en différentes classes.
- **Recurrent Neural Networks RNNs (Réseaux de neurones récurrents)** : Les RNNs sont un type de modèle de deep learning couramment utilisé pour les tâches séquence-à-séquence, comme la traduction automatique et la génération de texte. Ils sont particulièrement efficaces pour traiter des données séquentielles, car ils peuvent mémoriser des informations issues des étapes précédentes.

PLUSIEURS TECHNIQUES DE MACHINE LEARNING ET DEEP LEARNING UTILISÉES POUR LE NLP

- **Convolutional Neural Networks CNNs (Réseaux de neurones convolutifs):** Les CNNs sont un type de modèle de deep learning couramment utilisé pour la classification de textes et l'analyse de sentiments. Ils fonctionnent en appliquant une série de filtres aux données d'entrée afin d'extraire des caractéristiques pertinentes.
- **Transformers:** Les modèles Transformers, tels que BERT, GPT-2, GPT-3 et XLNet, sont un type de modèle de deep learning conçu pour les tâches de TALN. Ils utilisent un mécanisme d'auto-attention pour traiter le texte en entrée et ont atteint des performances de pointe (state-of-the-art) sur plusieurs benchmarks en NLP, tels que la compréhension du langage et la génération de texte.

Il existe plusieurs techniques de machine learning et de deep learning qui peuvent être utilisées pour les tâches de NLP, et le choix du modèle dépend de la tâche spécifique et des données disponibles.



TP 02