

M1 Data Lakes / Data Intégration

QUIZ NLP

Valentin Massonnière

M1-DE3

Question 1 : Large Language Models (LLMs) vs Mini-LLMs (8 points)

Définir et comparer les Large Language Models (LLMs) et les Mini-LLMs (ou LLMs compacts). Votre réponse doit inclure :

- Différences architecturales : nombre de paramètres, besoins en mémoire, taille de la fenêtre de contexte et efficacité computationnelle. (2 points)
- Compromis (Trade-offs) : discuter l'équilibre entre performance, adaptabilité et efficacité énergétique. (2 points)
- Exemples de Mini-LLMs. (2 points)
- Expliquer brièvement comment ces modèles compacts peuvent étendre les applications de GenAI aux appareils en périphérie (edge devices) et aux déploiements sur site (onpremise). (2 points)

Les LLMs sont de très grands réseaux de neurones pré-entraînés sur une quantité gigantesque de données afin de répondre à un vaste groupe de tâches. Contrairement à aux mini-LLMs, ce sont des versions compactes et optimisées pour répondre à une ou des tâches spécifiques avec une performance plus élevée.

type	LLMs	mini-LLMs
exemple	gpt-4, claude	Llama 3 8B
nombre de paramètres	> 100 milliards	< 15 milliards
besoin en mémoire	difficile à faire tourner et fonctionnent généralement sur des gpu industriels	fonctionnent sur des gpu grand public comme Nvidia ou sur des cpu de MacBook.
fenêtre de contexte	très large, permettant d'analyser des livres, des manuels ... généralement 1 million de tokens	fenêtre restreinte environ 30k tokens
efficacité computationnel	coût d'inférence très élevé et infrastructures massives	très rapide, optimisé pour la performance et le débit (token/s)

Le choix entre un LLM et un mini-LLM se détermine en fonction de la performance/généralisation, l'adaptabilité et efficacité énergétique. Les LLMs possèdent une connaissance plus importante tandis que les mini-LLMs sont performants sur le langage, la syntaxe et leurs domaines sur lesquels ils ont été finis-tunés. Ils hallucinent davantage sur des sujets plus obscurs.

Les LLMs sont adaptables, ils peuvent apprendre une nouvelle tâche avec quelques exemples. A l'inverse, les mini-LLMs nécessitent souvent un fine tuning pour performer dans un domaine spécifique.

Entraîner et faire tourner un LLM en local a un coût carbone énorme. Les Mini-LLMs permettent une consommation moins importante par rapport à un LLM.

Exemples de mini-LLMs :

Mistral 7B (Mistral AI), Llama 3 - 8B (Meta) et Gemma (Google)

Les mini-LLMs révolutionnent l'IA générative en sortant du modèle "Cloud API"

Pour un déploiement en local (Edge Devices), les données ne quittent jamais l'appareil de l'utilisateur. Essentiel pour les domaines médical, juridique ... Ils fonctionnent sans connexion extérieur et aucune latence de serveur est présente car celui-ci répond instantanément.

Pour un déploiement sur site (On-Premise), une entreprise peut héberger des mini-LLMs grâce à leurs tailles réduite (comme Mistral 7B ou Gemma) sur ses propres serveurs privés pour un coût réduit. Cela permet aussi la garantie que les données ne quittent jamais le site.

Question 2 : Comparaison entre NLP basé sur LLM, NLP basé sur RAG et IA Agentique pour le NLP (12 points)

Dans le domaine du Natural Language Processing (NLP), les différentes générations de systèmes intelligents reflètent une évolution, passant de la génération statique à un raisonnement autonome.

Les LLMs tels que GPT, Llama ou Mistral génèrent un texte proche du langage humain uniquement à partir de leurs connaissances pré-entraînées. Ils excellent dans la compréhension et la production du langage naturel, mais restent limités par leur mémoire statique ; ils ne peuvent pas accéder à des informations au-delà de ce qu'ils ont appris durant leur entraînement.

Pour surmonter cette limite, le RAG (Retrieval-Augmented Generation) a été introduit, combinant récupération augmentée et génération. Les systèmes RAG enrichissent le contexte du modèle avec des informations externes à jour, récupérées depuis une base de connaissances ou une base de vecteurs, avant la génération du texte, améliorant ainsi considérablement la précision factuelle.

L'IA Agentique appliquée au NLP, va au-delà de la génération et de la récupération : Ce paradigme introduit l'autonomie, les boucles de raisonnement et l'utilisation d'outils, permettant au système

- Fournir un tableau comparatif présentant les différences entre les trois paradigmes : NLP basé sur LLM, NLP basé sur RAG, IA Agentique pour le NLP. (6 points)
- Donner un exemple de scénario illustrant comment un Agent IA pourrait orchestrer plusieurs LLMs ou Mini-LLMs pour résoudre une tâche NLP complexe (ex. : analyse multi-documents ou synthèse automatisée de connaissances). (6 points)

critère	NLP basé sur LLM	NLP basé sur RAG	IA Agentique pour le NLP
source de connaissance	uniquement ce qui a été appris durant l'entraînement	connaissance paramétrable et connaissance externe injectée dans le contexte au moment de la requête	cherche l'information mais utilise des outils pour créer de nouvelles données pour agir sur l'environnement
mécanisme	le modèle complète le texte en fonction de patrons statistiques appris pendant l'entraînement	convertit la demande en vecteur, trouve les documents les plus proches et génère la réponse en fonction de ses documents	observe, raisonne, agit, constate le résultat et répète jusqu'à avoir un résultat correct
accuracy	sensible aux hallucinations si l'information est obscure ou trop ancienne.	hallucinations réduites parce que le modèle est forcé de se baser sur le contexte présent dans la requête	l'agent peut vérifier ses propres réponses pour valider celle-ci
cas d'usage	rédaction, traduction, résumé ...	chatbot, recherche de documents ...	assistants personnels, workflow automatique, codage autonome ...

Scénario : Analyse complexe et approfondie de plusieurs documents

Un LLM comme GPT-4 reçoit la requête et planifie les étapes et divise le travail.

Les mini-LLMs travaillent en parallèle : l'un analyse le document A et l'autre le document B ...

Le LLM reçoit les réponses des mini-LLMs et vérifie les réponses grâce à une recherche RAG et rédige un rapport final.