

Natural Language Processing

Partie prérequis au module NLP : Intro à l'IA/ML

TP Prétraitement et Exploration de données (EDA)

(Points Bonus/Malus)

Vous devez soumettre vos livrables sur MOODLE, en respectant la date limite fixée par votre formateur. Soumettez votre propre travail. La triche ne sera pas tolérée et sera pénalisée. Cette activité peut être réalisée en groupe (jusqu'à 4 membres par groupe).

Veillez noter que ceci n'est pas une tâche évaluée. Cependant, cette activité contribuera des points bonus ou malus à votre note globale.

Votre formateur vous a fourni du code pour vous aider à comprendre comment charger, inspecter, nettoyer, explorer et préparer vos données pour l'apprentissage automatique. N'hésitez pas à explorer le code et à comprendre les étapes de l'EDA (Analyse exploratoire des données) en Python. Cela vous aidera à saisir le concept de prétraitement des données pour l'apprentissage automatique.

Notez que vous devez expérimenter l'analyse exploratoire des données et le prétraitement des données. Ainsi, en réalisant ce TP, vous commencerez à coder en suivant les instructions données dans la Partie 1 - Analyse exploratoire de la qualité du vin, puis vous explorerez un exemple plus avancé dans la Partie 2 - Analyse de la satisfaction des compagnies aériennes et le prétraitement des données pour l'apprentissage automatique.

Partie 1 – Analyse exploratoire de la qualité du vin (Partie Notée : Bonus/Malus)
--

Introduction

Dans cette activité, vous travaillerez avec un ensemble de données contenant des informations sur différentes caractéristiques de différents types de vin, ainsi que leurs notes de qualité. Votre objectif est de prétraiter les données et de réaliser des visualisations de niveau intermédiaire, en tenant compte des données manquantes et aberrantes.

Objectifs

Charger et examiner les données

Prétraiter les données

Réaliser des visualisations de niveau intermédiaire

Pré-requis

- Python 3.5 or later
- Jupyter Notebook
- pandas
- NumPy

- Matplotlib
- Seaborn
- Scikit-learn

Jeu de données

L'ensemble de données qui vous est fourni avec cette activité de laboratoire est un ensemble de données sur la qualité du vin, qui peut également être téléchargé depuis le référentiel UCI Machine Learning à l'adresse suivante : <https://archive.ics.uci.edu/ml/datasets/wine+quality>

Instructions

1. Préparer votre environnement de développement et créez votre premier notebook Jupyter.

Tout d'abord, créez un notebook Jupyter dans votre environnement de développement, que ce soit Google Colab ou Anaconda.

Si vous n'avez pas encore préparé votre environnement de développement, référez-vous aux documents d'assistance qui vous ont été fournis pour vous aider à commencer à travailler avec Google Colab ou Anaconda Jupyter, avec quelques directives et tutoriels d'introduction :

- Intro to Anaconda Free Distribution & Installation Tutorial
- Intro to Google Colab Tutorial

2. Charger et examiner les données

Tout d'abord, vous allez charger les données à partir du fichier **winequality.csv** dans un DataFrame pandas et les examiner :

```
import pandas as pd

# Load the data
df = pd.read_csv("winequality.csv")

# Examine the data
print(df.head())
```

La méthode head() affichera les cinq premières lignes du DataFrame. Vous pouvez voir que l'ensemble de données contient 11 caractéristiques et une variable cible (qualité). Vous utiliserez cette variable cible pour prédire la qualité du vin.

3. Prétraiter les données

Ensuite, vous allez prétraiter les données pour les préparer à la modélisation. Vous commencerez par vérifier la présence de **valeurs manquantes** :

```
# Check for missing values
print(df.isnull().sum())
```

Vous devriez constater la présence de valeurs manquantes dans l'ensemble de données. Vous allez imputer les valeurs manquantes en utilisant la moyenne. **NB** : Notez que le remplacement par la moyenne n'est pas toujours une bonne solution. Il existe d'autres techniques pouvant être utilisées pour remplir les données manquantes.

```
# Impute missing values with the mean
df.fillna(df.mean(), inplace=True)

# Verify that there are no more missing values
print(df.isnull().sum())
```

Maintenant que vous avez imputé les valeurs manquantes, vous allez vérifier s'il y a **des points de données aberrants**. Vous commencerez par examiner le résumé statistique des caractéristiques :

```
# Examine the statistical summary of the features
print(df.describe())
```

Cela vous montrera la moyenne, l'écart type, la valeur minimale, la valeur maximale et les valeurs quartiles pour chaque caractéristique. Vous pouvez ensuite rechercher les caractéristiques présentant une grande différence entre la moyenne et les valeurs maximales ou minimales, car cela pourrait indiquer la présence de points de données aberrants.

Par exemple, supposons que vous remarquiez que la caractéristique "total sulfur dioxide" présente une grande différence entre la moyenne et la valeur maximale :

```
count    1599.000000
mean       46.896257
std       32.145059
min         6.000000
25%       23.000000
50%       40.000000
75%       61.000000
max      289.000000
```


La valeur maximale de 289 est bien plus élevée que la moyenne de 46,9, vous pourriez donc soupçonner la présence de quelques points de données aberrants dans cette caractéristique. Pour le confirmer, vous pouvez créer un **graphique en boîte (box plot)** de la caractéristique :

```
# Create a box plot of the "total sulfur dioxide" feature
plt.boxplot(df["total sulfur dioxide"])
plt.show()
```

Cela vous montrera les **valeurs aberrantes (outliers)** dans la caractéristique. Si vous trouvez des valeurs aberrantes, vous pouvez les supprimer en utilisant la méthode de la plage interquartile (IQR) (**Interquartile Range (IQR) method**) :

```
# Calculate the IQR for the "total sulfur dioxide" feature
Q1 = df["total sulfur dioxide"].quantile(0.25)
Q3 = df["total sulfur dioxide"].quantile(0.75)
IQR = Q3 - Q1

# Remove aberrant data points
df = df[~((df["total sulfur dioxide"] < (Q1 - 1.5 * IQR)) | (df["total sulfur dioxide"] > (Q3 + 1.5 * IQR)))]
```



Cela supprimera tout point de données qui est à plus de 1,5 fois la plage interquartile (IQR) des valeurs du quartile supérieur ou inférieur. Vous pouvez répéter ce processus pour toutes les autres caractéristiques qui contiennent des points de données aberrants.

4. Réaliser des visualisations de niveau intermédiaire

Maintenant que vous avez prétraité les données, vous réaliserez des visualisations de niveau intermédiaire pour **explorer les relations entre les caractéristiques et la variable cible**.

Tout d'abord, vous créerez un **histogramme** de la variable cible :

```
# Create a histogram of the target variable
import matplotlib.pyplot as plt

plt.hist(df["quality"])
plt.xlabel("Quality")
plt.ylabel("Count")
plt.show()
```

Vous devriez voir un histogramme des notes de qualité. Recherchez des modèles ou des distributions qui pourraient nous aider à prédire la variable cible.

Ensuite, vous créerez une carte de chaleur (**Heatmap**) pour visualiser la **corrélation** entre les caractéristiques :

```
# Create a heatmap of the correlation between the features
```

```
import seaborn as sns

corr = df.corr()
sns.heatmap(corr, annot=True, cmap="coolwarm")
plt.show()
```

Vous devriez voir une carte de chaleur qui visualise la corrélation entre les caractéristiques. Recherchez d'éventuelles corrélations fortes entre les caractéristiques, car elles pourraient indiquer une multicollinéarité.

Enfin, vous créerez une matrice de diagrammes de dispersion (**scatter plot matrix**) pour visualiser les relations entre les caractéristiques et la variable cible :

```
# Create a scatter plot matrix
sns.pairplot(data=df, vars=["fixed acidity", "volatile acidity", "citric acid", "residual sugar",
"chlorides", "free sulfur dioxide", "total sulfur dioxide", "density", "pH", "sulphates",
"alcohol"], hue="quality")
```

Vous devriez voir une matrice de diagrammes de dispersion qui visualise les relations entre les caractéristiques et la variable cible. Recherchez d'éventuels modèles ou corrélations qui pourraient vous aider à prédire la variable cible.

Partie 2 – Analyse exploratoire de la satisfaction dans les compagnies aériennes et prétraitement des données pour l'apprentissage automatique.

Dans cette partie, vous traiterez un problème de prédiction de la satisfaction des passagers de compagnies aériennes, résolu à l'aide de deux modèles d'apprentissage automatique différents : un classificateur d'arbres de décision et un classificateur de forêt aléatoire.

Explorez le code source qui vous est fourni pour comprendre l'analyse exploratoire des données (EDA), le prétraitement des données et la mise en œuvre de l'apprentissage automatique.

L'ensemble de données contient des données collectées après une enquête de satisfaction des passagers de compagnies aériennes. Il comprend les variables suivantes :

- Gender: Gender of the passengers (Female, Male)
- Customer Type: The customer type (Loyal customer, disloyal customer)
- Age: The actual age of the passengers
- Type of Travel: Purpose of the flight of the passengers (Personal Travel, Business Travel)
- Class: Travel class in the plane of the passengers (Business, Eco, Eco Plus)
- Flight distance: The flight distance of this journey
- Inflight wifi service: Satisfaction level of the inflight wifi service (0:Not Applicable;1-5)
- Departure/Arrival time convenient: Satisfaction level of Departure/Arrival time convenient
- Ease of Online booking: Satisfaction level of online booking
- Gate location: Satisfaction level of Gate location
- Food and drink: Satisfaction level of Food and drink
- Online boarding: Satisfaction level of online boarding
- Seat comfort: Satisfaction level of Seat comfort
- Inflight entertainment: Satisfaction level of inflight entertainment

- On-board service: Satisfaction level of On-board service
- Leg room service: Satisfaction level of Leg room service
- Baggage handling: Satisfaction level of baggage handling
- Check-in service: Satisfaction level of Check-in service
- Inflight service: Satisfaction level of inflight service
- Cleanliness: Satisfaction level of Cleanliness
- Departure Delay in Minutes: Minutes delayed when departure
- Arrival Delay in Minutes: Minutes delayed when Arrival
- Satisfaction: Airline satisfaction level(Satisfaction, neutral or dissatisfaction)

Vous utiliserez ces données pour répondre aux questions principales suivantes :

Quels sont les facteurs fortement corrélés à un passager satisfait (ou insatisfait) ?

Pouvez-vous prédire la satisfaction des passagers ?

Le jeu de données et le notebook python vous sont fournis avec cette activité. Ils sont également disponibles en ligne :

Vous pouvez télécharger le jeu de données depuis :

<https://lnkd.in/db7hsAvZ>

Le notebook python est accessible sur Google Colab en utilisant le lien suivant :

<https://lnkd.in/dRNHr25s>

Crédit : Notez que cette analyse a été réalisée et partagée en ligne par Michael Wiryaseputra.

Bonne chance !