

Natural Language Processing

TP 02 – Classification automatique de textes

TP noté (Évaluation continue)

Vous devez soumettre vos livrables sur MOODLE, en respectant la date limite fixée par votre formateur. Soumettez votre propre travail. La triche ne sera pas tolérée et sera pénalisée. Cette activité peut être réalisée en groupe (jusqu'à 4 membres par groupe).

Natural Language Processing

Le **Natural Language Processing (NLP)** / le **Traitement Automatique du Langage Naturel** est un sous-domaine de l'intelligence artificielle qui vise à permettre aux ordinateurs de comprendre, interpréter et manipuler le langage humain.

Il combine des techniques issues de l'informatique, de la linguistique et des statistiques pour traiter et analyser de grands volumes de données textuelles.

Quelques exemples d'applications du NLP :

- **Analyse de sentiments :**
Analyser et comprendre les sentiments exprimés dans des données textuelles (avis clients, posts sur les réseaux sociaux, enquêtes).
Utile pour mesurer la satisfaction client, suivre la réputation d'une marque et prendre des décisions basées sur les données.
- **Traduction automatique :**
Traduire automatiquement un texte d'une langue à une autre.
Utile pour les individus et les entreprises devant communiquer dans plusieurs langues.
- **Chatbots :**
Développer des agents conversationnels capables d'interagir en langage naturel.
Applications : support client, assistants personnels, etc.
- **Reconnaissance vocale :**
Transformer la parole en texte.
Utile pour les assistants vocaux, logiciels de dictée, centres d'appels.
- **Reconnaissance d'entités nommées (NER) :**
Identifier et extraire des entités (personnes, organisations, lieux) dans un texte.
Applications : extraction d'information, gestion des connaissances, résolution d'entités.

Le NLP a une large gamme d'applications et devient de plus en plus important dans un monde guidé par les données.

Certaines Techniques de Machine Learning et Deep Learning utilisées pour le NLP:

- **Classifieur de Naive Bayes** : algorithme probabiliste simple, utilisé pour la classification de texte (analyse de sentiments, détection de spam, modélisation de sujets).
- **Machines à vecteurs de support (SVM)** : largement utilisées pour la classification de texte et l'analyse de sentiments. Elles séparent les données en classes distinctes grâce à un hyperplan.
- **Réseaux de neurones récurrents (RNN)** : modèles de Deep Learning adaptés aux tâches séquence-à-séquence (traduction automatique, génération de texte). Ils mémorisent des informations des étapes précédentes.
- **Réseaux de neurones convolutifs (CNN)** : utilisés pour la classification de texte et l'analyse de sentiments, en appliquant des filtres aux données pour extraire des caractéristiques pertinentes.
- **Transformers** : BERT, GPT-2, GPT-3... modèles de Deep Learning basés sur l'auto-attention, atteignant des performances de pointe en compréhension et génération du langage.

Le choix de la technique dépend de la tâche spécifique et des données disponibles.

Le Processus du NLP

Le **processus de traitement automatique du langage naturel** comprend plusieurs étapes, notamment le prétraitement et le nettoyage des données, la tokenisation et la vectorisation avec des techniques d'embeddings de mots. Voici un aperçu du processus de NLP :

- **Prétraitement et nettoyage des données** :
La première étape du NLP consiste à prétraiter et nettoyer les données. Cela implique de supprimer tous les caractères inutiles, tels que la ponctuation et les chiffres, de convertir tout le texte en minuscules et de supprimer les mots vides (stop words), c'est-à-dire les mots courants tels que « the », « and » et « a », qui sont peu susceptibles d'être informatifs. Cette étape est importante pour améliorer la qualité des données et réduire le bruit.
- **Tokenisation** :
La tokenisation est le processus qui consiste à découper le texte en unités plus petites appelées tokens. Il existe plusieurs techniques de tokenisation, y compris la tokenisation au niveau des mots, qui divise le texte en mots individuels, et la tokenisation au niveau des caractères, qui divise le texte en caractères individuels. La tokenisation est importante car elle permet de traiter le texte à un niveau plus fin et d'en extraire des caractéristiques significatives.
- **Vectorisation** :
Après la tokenisation, l'étape suivante consiste à convertir le texte en vecteurs numériques qui peuvent être utilisés comme entrée pour les modèles de machine

learning. Les techniques d'embeddings de mots, telles que Word2Vec et GloVe, sont couramment utilisées à cette fin. Les word embeddings associent chaque mot à un vecteur de grande dimension de manière à capturer son sens et son contexte. Cela nous permet de représenter le texte d'une façon que les modèles de machine learning peuvent comprendre et traiter.

- **Modélisation et évaluation :**

Après la vectorisation, l'étape finale consiste à entraîner et évaluer des modèles de machine learning sur les données. Les modèles couramment utilisés pour les tâches de NLP incluent Naive Bayes, les machines à vecteurs de support (SVM – Support Vector Machines) et les réseaux de neurones récurrents (RNN – Recurrent Neural Networks). Le choix du modèle dépend de la tâche spécifique et des données disponibles.

En résumé, le processus de NLP comprend plusieurs étapes, notamment le prétraitement et le nettoyage des données, la tokenisation et la vectorisation avec des techniques d'embeddings de mots, etc. En suivant ces étapes, nous pouvons convertir des données textuelles brutes en vecteurs numériques qui peuvent être utilisés comme entrée par des modèles de machine learning pour diverses tâches de NLP.

Application du NLP à des tâches de classification

TP 2.1 et TP 2.2 (non notés)

TP 2.3 (noté)

Dans cette activité pratique, vous allez analyser une étude de cas en appliquant le NLP.

À cette fin, vous devez :

- Mener une brève revue de littérature sur les techniques et algorithmes de NLP (tokenisation, word embeddings, machine learning & deep learning appliqués NLP, etc.).
- Identifier une étude de cas de votre choix, liée à n'importe quel domaine (business, santé, médical, financier, ...). Une fois que vous avez décidé quel cas d'étude vous intéresse, trouvez et sélectionnez un jeu de données disponible en ligne qui soit le plus adapté pour mener votre analyse.
- Appliquer ensuite le NLP en utilisant les techniques de prétraitement, tokenisation, vectorisation, et les modèles de machine learning ou de deep learning de votre choix, que vous jugez les plus pertinents pour votre cas d'usage.

Pour vous aider, ci-dessous figurent deux exemples d'études de cas utilisant le NLP. Ensuite, vous allez avoir la possibilité de choisir n'importe le cas d'usage de votre choix, ce qui signifie que vous n'êtes pas limités à ces deux exemples, mais vous pouvez les explorer pour vous en inspirer.

TP 2.1: Classification de Restaurants Reviews

Cet exemple correspond à un problème de classification en traitement automatique du langage.

Il existe plusieurs algorithmes de classification qui ont été appliqués à divers problèmes de NLP. Par exemple, Naive Bayes a été utilisé dans divers algorithmes de détection de spam, et les machines à vecteurs de support (SVM) ont été utilisées pour classer des textes tels que les notes de suivi dans les institutions de santé. Il serait intéressant d'implémenter une version simple de ces algorithmes.

Pour ce cas d'usage, une analyse prédictive est menée sur les avis de restaurants. Les techniques de NLP sont utilisées pour nettoyer et préparer les données non structurées, puis un modèle de classification est appliqué pour classer et prédire si les avis sont positifs ou négatifs.

Le modèle de classification utilisé est le Naive Bayes gaussien, recommandé et le plus couramment utilisé pour le NLP d'après les expérimentations pour ce type de use case.

Consultez le code source fourni avec un document guidé :

TP 2.1 – NLP for Restaurant Reviews Classification

(Réf. K.E, H.DP, @SuperDataScience)

Pour une introduction guidée, vous pouvez aussi consulter :

<https://www.geeksforgeeks.org/nlp/python-nlp-analysis-of-restaurant-reviews/>

TP 2.2: Classification de Wine Reviews

Ceci est un exemple d'utilisation d'un modèle de Deep Learning appliqué à la compréhension des critiques de vins rédigées par des experts, afin de déduire le cépage du vin évalué.

Il s'agit d'un modèle de classification en Deep Learning développé et partagé par S. Wang.

Vous pouvez trouver l'explication de l'étude de cas et des techniques de NLP et DL utilisées en cliquant sur le lien suivant :

<https://www.toptal.com/machine-learning/nlp-tutorial-text-classification>

Le code est disponible sur GitHub :

https://github.com/shanglun/or_posts

Consultez également le code source fourni avec ce document : **TP 2.2 – NLP for Wine Reviews Classification** (Réf. Git par S. Wang).

TP 2.3 – Activité notée**Instructions:**

- Identifier un cas d'usage de votre choix pour appliquer le NLP et implémenter un modèle de classification afin d'analyser les données textuelles, évaluer sa performance et interpréter les résultats.
- Choisir le modèle que vous souhaitez utiliser pour votre étude de cas, et vous assurer de bien comprendre les raisons qui motivent ce choix.
- Trouver un jeu de données disponible en ligne adapté à votre étude, l'explorer, le nettoyer et le préparer si nécessaire. (60% de la note globale)
- Implémenter les techniques de NLP et le modèle de ML ou DL choisi afin de réaliser les prédictions nécessaires. (25% de la note globale)
- Évaluer la performance de votre modèle. (15% de la note globale)
- **NB : n'oubliez pas d'ajouter des commentaires internes d'interprétation des résultats et d'explication du code à chaque étape. Ceci est obligatoire et sera noté.**

L'absence de ces commentaires entraînera une perte de points à chaque étape.

- **Pour des points bonus (optionnel) :** vous pouvez implémenter deux modèles différents, les comparer et expliquer, dans votre cas, lequel a donné les meilleurs résultats et pourquoi..

Livrables attendus :

- Le jeu de données
- Un **Notebook Python** comprenant :
 - La description de votre cas d'usage
 - Le code source
 - Les sorties (tableaux, graphiques, résultats imprimés)
 - Des commentaires internes expliquant et interprétant les résultats

Veillez respecter la date limite de soumission des livrables sur **MOODLE**.

Les commentaires internes doivent inclure :

- Une introduction présentant le contexte, le cas d'usage et le jeu de données
- Une explication des techniques de traitement utilisées (prétraitement, nettoyage, tokenisation, vectorisation)
- Une explication du modèle de machine learning ou de deep learning utilisé
- Une justification du choix des techniques et modèles NLP + ML ou DL sélectionnés
- Des explications intégrées au code pour clarifier l'implémentation
- Une interprétation des résultats (performance du modèle, etc.)

Bonne chance !